



Wydział Matematyki i Nauk Informatycznych

POLITECHNIKA WARSZAWSKA

ANALIZA I PRZETWARZANIE DŹWIĘKU

PROJEKT 3

Rozpoznawanie mowy

Autorzy

Franciszek NIEDŹWIECKI

Igor OLEKSY

27 maja 2026

Spis treści

1	Wstęp	2
1.1	Cel projektu	2
1.2	Zastosowane metody analizy i klasyfikacji	2
2	Architektura systemu i przetwarzanie sygnału	2
2.1	Przetwarzanie wstępne	2
2.2	Ekstrakcja cech - Parametryzacja	3
3	Algorytm klasyfikacji (DTW + k-NN)	3
3.1	Dynamiczne Dopasowanie Czasu (DTW)	3
3.2	Klasyfikator k-NN	3
4	Eksperymenty i wyniki	4
4.1	Wizualizacja macierzy kosztów i optymalnej ścieżki DTW	4
4.2	Działanie systemu dla słów ze słownika oraz spoza niego	4
4.3	Podsumowanie i wnioski	5

1 Wstęp

1.1 Cel projektu

Głównym celem zrealizowanego projektu było zaprojektowanie, zaimplementowanie oraz przetestowanie systemu rozpoznawania mowy, służącego do klasyfikacji wyizolowanych słów. Utworzona aplikacja została wyposażona w graficzny interfejs użytkownika, który pozwala na rejestrację sygnału mowy bezpośrednio z mikrofonu, wczytywanie nagrań z zewnętrznych plików dźwiękowych (.wav) oraz zaawansowaną wizualizację sygnałów w dziedzinie czasu, a także analizę wyników dopasowania na macierzy kosztów.

1.2 Zastosowane metody analizy i klasyfikacji

W procesie automatycznego rozpoznawania mowy kluczowym etapem jest transformacja surowego sygnału w zestaw reprezentatywnych cech deterministycznych. W ramach niniejszego projektu zaimplementowano i poddano analizie porównawczej dwa odmienne podejścia do parametryzacji sygnału:

1. **Widmo częstotliwościowe (FFT):** Podejście klasyczne, opierające się na podziale sygnału na ramki i wyznaczeniu ich surowego widma amplitudowego za pomocą Szybkiej Transformaty Fouriera.
2. **Współczynniki mel-cepstralne (MFCC – *Mel-Frequency Cepstral Coefficients*):** Zaawansowana metoda parametryzacji uwzględniająca nieliniową percepcję częstotliwości przez ludzki układ słuchowy, bazująca na skali Mel.

Do procesu klasyfikacji, polegającego na porównywaniu cech z nagrania testowego ze wzorcami zgromadzonymi w bazie danych, zastosowano algorytm Dynamic Time Warping (Dynamiczne Dopasowanie Czasu). Algorytm ten został rozszerzony o metodę k-najbliższych sąsiadów, co pozwoliło na uodpornienie systemu na błędy pojedynczych wzorców i znaczące zwiększenie precyzji klasyfikacji.

2 Architektura systemu i przetwarzanie sygnału

System został zaprojektowany jako potok, w którym sygnał audio przechodzi przez kolejne etapy obróbki.

2.1 Przetwarzanie wstępne

Przed przystąpieniem do właściwej ekstrakcji cech, surowy sygnał audio poddawany jest trzem etapom przetwarzania wstępnego, których kolejność ma kluczowe znaczenie dla poprawności działania algorytmów:

1. **Normalizacja amplitudy:** Sygnał jest skalowany w taki sposób, aby jego maksymalna amplituda odpowiadała maksymalnej wartości dla formatu 16-bitowego (32767). Niweluje to różnice w głośności pomiędzy nagraniami pochodzącymi z różnych mikrofonów lub nagranymi z różnej odległości.
2. **Detekcja aktywności głosu (VAD - *Trim Silence*):** Algorytm oparty na analizie energii sygnału w oknach czasowych usuwa ciszę na początku i na końcu nagrania. Analizowana jest maksymalna głośność (w dB), a następnie ucinane są fragmenty sygnału leżące poniżej ustalonego progu odniesienia (np. 25 dB poniżej maksimum), z zachowaniem odpowiedniego marginesu bezpieczeństwa zapobiegającego ucięciu bezdźwięcznych spółgłosek.
3. **Preemfaza:** Sygnał przepuszczany jest przez filtr górnoprzepustowy (o współczynniku $\alpha = 0.97$), co pozwala na podbicie wyższych częstotliwości, które ulegają naturalnemu tłumieniu w trakcie propagacji dźwięku.

2.2 Ekstrakcja cech - Parametryzacja

Kluczowym dla skuteczności rozpoznawania mowy był dobór odpowiednich parametrów okienkowania. W systemie zastosowano okna o długości 25 ms przesuwające się co 10 ms.

Domyślną i najskuteczniejszą metodą parametryzacji w zaimplementowanym systemie są współczynniki MFCC. Proces ich wyznaczania składa się z następujących kroków:

1. Obliczenie widma amplitudowego za pomocą transformaty Fouriera.
2. Przefiltrowanie widma przez zestaw 26 trójkątnych filtrów rozłożonych równomiernie w nieliniowej skali Mel. Górna granica pasma została ograniczona do 8000 Hz, ponieważ to w tym przedziale znajduje się większość użytecznych informacji fonetycznych.
3. Zlogarytmowanie otrzymanych energii w każdym z pasm.
4. Zastosowanie Dyskretnej Transformaty Kosinusowej.
5. Odejmowanie średniej cepstralnej : Z całego nagrania wyznaczana jest wartość średnia dla każdego współczynnika, a następnie odejmowana od każdej ramki. Eliminuje to wpływ stałych zniekształceń kanału transmisyjnego (np. charakterystyki konkretnego mikrofonu).

3 Algorytm klasyfikacji (DTW + k-NN)

3.1 Dynamiczne Dopasowanie Czasu (DTW)

Algorytm DTW pozwala na pomiar podobieństwa dwóch sekwencji o różnej długości czasowej. Jest to kluczowe w analizie mowy, ponieważ to samo słowo może zostać wypowiedziane w różnym tempie.

W systemie wyznaczana jest macierz lokalnych odległości pomiędzy ramkami testowymi a referencyjnymi z wykorzystaniem odległości euklidesowej. Z uwagi na to, że cechy MFCC zostały poddane normalizacji CMS, dystans euklidesowy precyzyjnie odzwierciedla różnice w fonetyce. Pierwszy współczynnik MFCC (C_0), odpowiadający za energię ramy, został wykluczony z obliczeń, co uodporniło algorytm na lokalne fluktuacje głośności. Następnie, za pomocą programowania dynamicznego, wyznaczana jest optymalna ścieżka w macierzy kosztów, minimalizująca globalny koszt przejścia. Znormalizowany dystans wzdłuż tej ścieżki jest ostatecznym wynikiem porównania nagrań.

3.2 Klasyfikator k-NN

Aby zwiększyć odporność systemu na występowanie nietypowych lub błędnych nagrań wzorcowych w bazie, zastosowano wariant klasyfikatora k -najbliższych sąsiadów (k -NN). Zamiast przypisywać nagraniu testowemu etykietę pojedynczego wzorca o najmniejszym dystansie DTW, system wykonuje następujące operacje:


- Oblicza dystans DTW pomiędzy próbką testową a wszystkimi wzorcami w bazie.
- Wybiera zbiór $k = 3$ wzorców charakteryzujących się najmniejszym kosztem dopasowania.
- Grupuje wybrane wzorce po przypisanej im etykietie słowa i zlicza liczbę wystąpień (głosowanie większościowe).
- W przypadku remisu (np. 3 różne słowa na pierwszych 3 miejscach), decydującym kryterium staje się minimalny koszt DTW w danej grupie.

4 Eksperymenty i wyniki

W celu weryfikacji poprawności zaimplementowanych rozwiązań przeprowadzono testy systemu na przygotowanej bazie nagrań. Na potrzeby niniejszych eksperymentów bazę tę ograniczono wyłącznie do słów reprezentujących liczby od „zero” do „dziesięć”. Wynikało to z posiadania znacznej ilości nagrań od różnych mówców tych cyfr, co ułatwiło tworzenie bazy danych.

4.1 Wizualizacja macierzy kosztów i optymalnej ścieżki DTW

Pierwszy eksperyment polegał na analizie wzrokowej działania algorytmu dopasowania czasowego. Na rysunku 1 zaprezentowano wygenerowaną przez aplikację heatmapę macierzy lokalnych odległości dla dwóch nagrań przedstawiających to samo słowo, wypowiedziane w różnym tempie.




Rysunek 1: Wizualizacja dopasowania algorytmem DTW. Biała linia reprezentuje optymalną ścieżkę dopasowania, omijającą obszary o wysokim koszcie (jasne piksele).

Wykres potwierdza, że algorytm prawidłowo kompensuje nieliniowe przesunięcia w czasie. Płaskie fragmenty ścieżki odpowiadają momentom, w których jedno z nagrań było wyprawiane wolniej względem drugiego (np. wydłużenie samogłoski).

4.2 Działanie systemu dla słów ze słownika oraz spoza niego


Kolejny eksperyment miał na celu weryfikację zachowania systemu w dwóch skrajnych przypadkach: podania na wejście słowa obecnego w bazie (jedna z wprowadzonych liczb) oraz słowa całkowicie spoza zdefiniowanego słownika.



Rysunek 2: Wynik rozpoznania dla słowa znajdującego się w bazie (nagrana liczba 0-10).

Jak widać na rysunku 2, dla słów znajdujących się w bazie, znormalizowany koszt DTW osiąga relatywnie niskie wartości, a algorytm poprawnie przypisuje nagranie do właściwej klasy.

Zbadano również scenariusz, w którym do mikrofonu wypowiedziano słowo spoza zbioru uczącego (inne niż liczby od 0 do 10).



Rysunek 3: Wynik klasyfikacji dla słowa, którego nie ma w bazie wzorców ("krzesło").

Ze względu na specyfikę zastosowanego klasyfikatora (k -NN z wymuszonym przypisaniem do kandydata), system zawsze wskaże jako wynik jedno z dostępnych w bazie słów. Jednakże, jak ilustruje rysunek 3, wymuszone dopasowanie słowa obcego skutkuje drastycznym wzrostem znormalizowanego kosztu DTW. Z tego też powodu ustalono próg akceptacji eksperymentowo na 18 w przypadku użycia MFCC oraz 0.29 dla fft.

4.3 Podsumowanie i wnioski

Połączenie parametryzacji MFCC, odpowiednio zoptymalizowanych metod przetwarzania wstępnego (VAD, Normalizacja) oraz klasyfikatora DTW wraz z logiką k -NN, zaowocowało stabilnym i wydajnym systemem rozpoznawania mowy. Użycie $k=3$ dla zasady większościowej znacząco wyeliminowało sytuacje, w których pojedynczy uszkodzony lub nietypowo nagrany wzorzec w bazie psuł wynik końcowy dopasowania.

Dodatkowo, na podstawie przeprowadzonych eksperymentów, zaobserwowano istotne zależności pomiędzy wybraną metodą ekstrakcji cech a zastosowaną metryką odległości:

- Najwyższa skuteczność (MFCC + Odległość Euklidesowa): Zastosowanie współczynników cepstralnych w skali melowej (MFCC) w połączeniu z klasyczną odległością euklidesową okazało się najbardziej optymalnym i najskuteczniejszym rozwiązaniem. Wynika to z faktu, że cechy MFCC same w sobie podlegają de-korelacji (dzięki transformacji kosinusowej DCT), a ich wartości mają zbliżony zakres dynamiki, co sprawia, że geometryczny pomiar błędu (euklidesowy) precyzyjnie odzwierciedla różnice fonetyczne między nagraniami.
- Dobre rezultaty alternatywne (Widmo FFT + Metryka Kosinusowa): W przypadku wykorzystania surowego widma amplitudowego (FFT), system również osiągał zadowalające rezultaty, pod warunkiem zastosowania miary kosinusowej. Z racji tego, że wektory widma FFT charakteryzują się bardzo dużą rozpiętością wartości i są silnie uzależnione od absolutnej głośności nagrania, metryka kosinusowa — mierząca jedynie kąt pomiędzy wektorami, a ignorująca ich amplitudę — skutecznie niwelowała wahania energii sygnału u różnych mówców.

Podsumowując, dobór odpowiedniej miary podobieństwa musi być ściśle skorelowany ze sposobem ekstrakcji cech. System wykazał najwyższą odporność na zmienność mówców przy zastosowaniu zestawu MFCC z odległością euklidesową.